

# Yapay Zekâ Uygulamaları

## Ders 2

Ali Mertcan KOSE Msc.  
amertcankose@ticaret.edu.tr

İstanbul Ticaret Üniversitesi



İSTANBUL TİCARET  
ÜNİVERSİTESİ

Makine öğrenmesi, örnek verileri ya da geçmiş deneyimleri kullanarak bir performans kriterinde en uygunu elde etmek için bilgisayarların programlanmasıdır. Başka bir deyişle bazı parametreleri tanımlanmış bir modelin öğrenme, eğitim verilerini ya da geçmiş deneyimleri kullanarak modelin parametrelerinin en uygununu elde etmek için bir bilgisayar programının yürütülmesidir.

Model, geleceğe yönelik tahminler yapmak için öngörücü ya da verilerden bilgi edinmek için tanımlayıcı ya da her ikisi de olabilir. Bilgisayar oyunları ve yapay zekâ alanında önder bir Amerikalı bilim insanı olan Arthur Samuel, 1959'da IBM'deyken “Makine Öğrenmesi” terimini kullanmıştır ve makine öğrenmesi “bilgisayarlara açıkça programlanmadan öğrenmesi yeteneği veren çalışma alanı” olarak tanımlanmıştır. Ancak zekâ ya da yapay zekâda olduğu gibi makine öğrenmesi için de evrensel olarak kabul edilmiş bir tanım yoktur. Farklı yazarlar makine öğrenmesini farklı şekillerde tanımlanmışlardır.

Geleneksel programlamada bilgisayar ortamında program gerekli verileri alıp işleyerek istenilen çıkışları verir. Makine öğrenmesi, verileri iyileştirmek, açıklamak ve sonuçları tahmin etmek için yinelemeli olarak verilerden öğrenen çeşitli algoritmaları kullanır. Algoritmalar eğitim verilerini alırken, bu verilere dayalı olarak daha kesin modeller üretmek mümkündür. Bu makine öğrenmesi modeli, makine öğrenmesi algoritması verilerle eğitildiğinde üretilen çıktıdır. Eğitimden sonra girdili bir model sağlandığında model bir çıktı verecektir.

# Makine Öğrenmesi

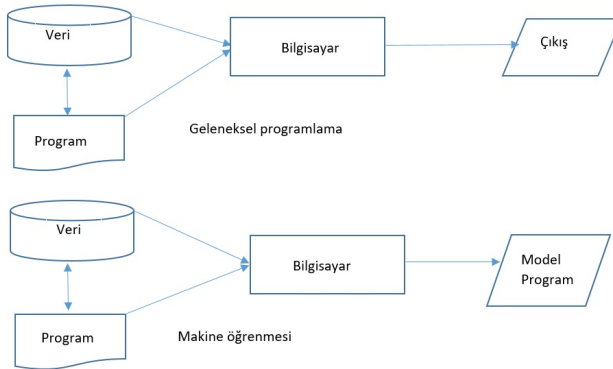


Figure 1: Geleneksel programlama ve makine öğrenmesi yapıları

Tahmin süreçlerine odaklanan bir algoritma, neticede tahmine dayalı bir model meydana getirecektir. Akabinde, ilgili modele veriler sağladığımızda, eğiti sağlamış verilerden yola çıkan bir tahmin alırız. Bu bağlamda analitik ve tahmin odaklı modelleri oluşturmak için makine öğrenmesi çok önemlidir. Makine öğrenmesi, kuruluşların yeni bir anlayış düzeyi kazanmasına yardımcı olmak için veri varlıklarından yararlanmanın yenilikçi yollarını arayan geliştirme organizasyonlarında en önemli konulardan biri haline gelmiştir.

Uygun makine öğrenmesi modelleriyle kuruluşlar, bir sonraki adımı en iyi şekilde tahmin edebilmeleri için isteki değişiklikleri sürekli olarak tahmin etme becerisine sahiptir. Veriler sürekli olarak eklendiğinden, makine öğrenmesi modelleri, çözümün sürekli güncellemesini sağlar. Kazanımlar açık bir şekilde bellidir: Makine öğrenmesi bağlamında en uygun ve sürekli değişen veri kaynakları kullanılırsa, geleceği tahmin etme fırsatı olur.

# Makine Öğrenmesi

Son birkaç on yılda makine öğrenmesi Bilgi teknolojisinin temel dayanağı haline geldi. Makine öğrenmesinin bir görüşü, deneyimlerden öğrenen sistemler oluşturma hedefiyle, örüntüleri bulma ve verilerden rahminler yapma bilimini temsil etmesidir. Makine öğrenmesi, çok değişkenli istatistikler, veri madenciliği, örüntü tanıma ve gelişmiş ve/ya da tahmini analitik ile sınırlanabilir.



Artan miktarda mevcut veri, makine öğrenmesinin teknolojik ilerlemenin daha yaygın bir bileşeni haline geleceğini göstermektedir. Makine öğrenmesi teknikleri genellikle denetimli, denetimsiz, yarı denetimli ve pekiştirmeli öğrenme gibi ana öğrenme tekniklerinden birine aittir. İlgili yöntemler arasında da karar ağaçları, en yakın komşu teknikleri bölümleme/hiyerarşik/yoğunluk tabanlı kümeleme, bayes yaklaşımları, çekirdek yöntemleri, sinir ağları ve derin öğrenme teknikler yer alır.

# MAKİNE ÖĞRENMESİNİN TEMELLERİ

Daha önce de bahsedildiği gibi akıllı, duyarlı ve kendini bilen makineler yapma fikri, som birkaç yılda aniden ortaya çıka bir şey değildir. Aslında yunan mitolojisinden pek çok bilgi akıllı makinelerden ve kendi öz farkındalığı ve zekâsına sahip icatlardan bahseder. Bilgisayarın kökenleri ve evrimi, 17. Yüzyıldaki temel abaküs ve onun soyundan gelen sürgülü hesap cetvelinden 1800'lerde Charles Babbage tarafından tasarlanan ilk genel amaçlı bilgisayara kadar, birkaç yüzyıllık bir süre boyunca gerçekten devrim niteliğinde olmuştur. Aslında, babbage tarafından analitik motorun icadı ve 1842'de Ada Lovelace tarafından yazılan ilk bilgisayar programı ile bilgisayarlar gelişmeye başladığında, insanlar bilgisayarların ya da makinelerin gerçekten zeki ve akıllı hale geldiği bir zamanının olabileceğini merak etmeye ve düşünmeye başlamışlardır.

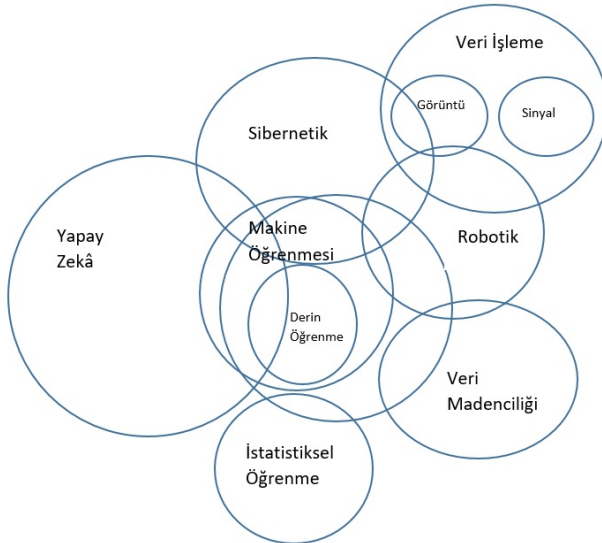
# MAKİNE ÖĞRENMESİNİN TEMELLERİ

Aslında, ünlü bilgisayar bilimcisi Alan Turing, teorik bilgisayar bilimi, algoritmalar ve biçimsel dilin geliştirilmesinde oldukça etkiliydi ve yapay zekâ ile makine öğrenmesi gibi kavramları 1950'lerin başlarında ele almıştır. Sonuç olarak günümüzde büyük bir ilgi alanı haline makinelerin öğrenmesi fikri kavramı olarak olmasa da fikir olarak sürekli dile getirilmiştir. Daha hızlı bilgisayarlar, daha iyi işleme, daha iyi hesaplama gücü ve daha fazla depolama ile “bilgi çağı” ya da “veri çağı” olarak adlandırılan bir zamanda, her gün, veri bilimi, yapay zekâ, veri madenciliği ve makine öğrenmesi kavramlarını ve metodolojilerini kullanarak büyük veriyi yönetmek ve akıllı sistemler oluşturmakla ilgili çalışmalar ortaya konuyor.

# MAKİNE ÖĞRENMESİNİN TEMELLERİ

Aşağıdaki görselde gösterildiği gibi makine öğrenmesi ve yapay zekânın yanı sıra veri madenciliği, derin öğrenme ve istatistiksel öğrenme terimleri birbirleriyle ilişkilidir, genellikle aynı bağlamda bulunur ve bazen birbirlerinin yerine kullanılır. Terimler farklı topluluklarda yaygın olmakla birlikte, özel kullanımları ve anlamları büyük ölçüde değişmektedir.

# MAKİNE ÖĞRENMESİNİN TEMELLERİ



# MAKİNE ÖĞRENMESİNİN TEMELLERİ

Şimdiye kadar, makine öğrenmesinin, makineleri akıllı hale getirme teknikleri, otomasyon sistemlerini otomatikleştirme, 21. Yüzyılın en gözde işi, bilgisayarların kendi kendine öğrenmesini sağlama gibi sayısız değişik makine öğrenmesi tanımıyla karşılaşmak mümkündür. Hepsi iyi alıntılar ve belirli ölçülerde doğru olsa da makine öğrenmesi tanımlamanın en iyi yolu, 1997 yılında ünlü Profesör Tom Mitchell tarafından tanımlanan makine öğrenmesi temellerinden başlamak olacaktır. Makine öğrenmesi fikri, makinenin verilerden öğrenmesine yardımcı olacak bazı öğrenme algoritmalarının olacağıdır. Profesör Mitchell bunu şu şekilde tanımlamıştır.

# MAKİNE ÖĞRENMESİNİN TEMELLERİ

“Bir bilgisayar programı, bazı görev sınıfları T, E deneyiminden öğreniyorsa ve performans ölçücü P ile değerlendiriliyorsa, P ölçüldüğü gibi T görevdeki performansı, E deneyimi ile iyileşir.” Kısaca açarsak bilgisayar programı görev(Task-T), deneyim (experience-E), performans (performance-P) bağlamında incelendiğinde; Eğer E deneyimlerinden faydalananarak, T görevlerindeki P performansı artıyorsa bu işlem makine öğrenmesidir.

# MAKİNE ÖĞRENMESİNİN TEMELLERİ

Gerçek dünyadaki sorunun çözümü için ele alınırsa, T görevlerinden biri altyapı için kesintileri tahmin etmek olabilir; deneyim E, çeşitlik cihaz veri özniteliklerinden kalıpları gözlemleyerek makine öğrenmesi modelinin zaman içinde kazanacağı şey olacaktır ve P modelin performansı, modelin kestirimleri ne kadar doğru tahmin ettiği gibi çeşitli yollarla ölçülebilir. Bir başka örnek olarak, el yazısı tanıma öğrenme problemi verelim: Görev T: el yazısıyla yazılmış kelimeleri resimle tanıma ve sınıflandırma, performans P: Doğru sınıflandırılmış kelimelerin yüzdesi, Eğitim deneyimi E: Verilen sınıflandırmalara sahip el yazısı kelimelerin bir veri setini temsil eder.



# Makine Öğrenmesinde Görevler

Makine öğrenmesi tabanlı görevlerin geleneksel ve geleneksel programlama yaklaşımlarıyla çözülmesi zordur. T görevi, genellikle sistemin veri noktaları ya da örnekler üzerinde çalışması için izlemesi gerek süreç ya da akışına dayalı bir makine öğrenmesi görevi olarak tanımlanabilir. Aşağıdaki popüler görevler makine öğrenmesi tabanlı görevler açıklanmıştır. Sınıflandırma ya da ayırıştırma: Sınıflandırma tipik olarak, makinenin veri noktalarını ya da örnekleri alması ve her bir örneğe belirli sınıf ya da grup ataması gereken sorunların ya da görevlerin listesini kapsar. Örneğin hayvan görüntülerini, köpekler, kediler ve zebralar olarak sınıflandırmak olabilir.

# Makine Öğrenmesinde Görevler

**Regresyon ya da tahmin:** Regresyon tabanlı görevler genelde girdi veri noktası için bir sınıf ya da grup yerine gerçek bir sayısal değerin çıktığı olduğu bir tahmin gerçekleştirilmeyi içerir. Bir regresyon görevini anlamamanın en iyi yolu, her veri noktası için girdi nitelikleri olarak arsa alanı, kat sayısı, banyolar, yatak odaları ve mutfak sayılarını göz önünde bulundurarak konut fiyatlarını tahmin etme gerçek dünya problemini ele alacaktır.

**Anormallik algılama:** Anormallik algılama, makinenin normal davranıştan farklı anormal ya da olağandışı desenler ya da olaylar bulabilmesi için olay günlüklerini, işlem günlüklerini ve diğer veri noktalarını gözden geçirmesini içerir. Buna örnek olarak, günlüklerden hizmet reddi saldırılarını, dolandırıcılık belirtileri bulmaya çalışmaktır.

# Makine Öğrenmesinde Görevler

**Yapılandırılmış açıklama(ilişkilendirme):** Yapılandırılmış açıklama genellikle girdi veri noktaları üzerinde bazı analizler yapmayı ve ek bilgiler ve veri öğeleri arasındaki ilişkileri gösteren orijinal verilere açıklama olarak yapılandırılmış meta veriler eklemeyi içerir. Basit örnekler, metne konuşma bölümleri, adlandırılmış varlıklar, dilbilgisi ve duygu ile açıklama eklemek olabilir.

**Çeviri:** Otomatik makine çevirisi görevleri tipik olarak, belirli bir dile ait girdi veri örnekleri varsa, bunu istenilen başka bir dile sahip çıktılara çevirebilir. Doğal dil tabanlı çeviri kesinlikle çok sayıda metin verisi ile uğraşan devasa bir alandır.

# Makine Öğrenmesinde Görevler

**Kümeleme ya da gruplandırma:** Kümeleme sayesinde çeşitli kümeler (ya da gruplar) genellikle, makinenin girdi veri noktalarının kendileri arasındaki doğal gizli örüntüleri, ilişkileri ve benzerlikleri öğrenmesini ya da gözlenmesini sağlayan girdi veri örneklerinden oluşur.

**Transkripsiyonlar:** Transkripsiyon genellikle verilerin sürekli ve yapılandırılmamış çeşitli temsilleri gerektirir. Bunları daha yapılandırılmış ve ayırık veri öğelerine dönüştürür. Örneğin, konuşmadan metne optik karakter tanıma, görüntülerden metne dönüştürmek sayılabilir. Buraya kadar sayılanlar genellikle makine öğrenmesi kullanılarak çözülen tipik görevler hakkında iyi bir fikir verse de görevlerin sınırları gerçekten sonsuz olduğundan ve zaman içinde kapsamlı araştırmalarla daha fazlası keşfedildiğinden bu liste kesinlikle sınırlı kalmaktadır.

# Makine Öğrenmesinde Deneyim

Makine öğrenmesinde deneyim E, T olarak adlandırdığımız belirli bir görevi gerçekleştirmek için gerekli olan geçmiş veriler üzerinden herhangi bir öğrenme algoritması eğitilmesi ile modelin görevin durumlarını öğrenmesidir. Böylece öğrenme algoritması tarafından kazanılan deneyim E olarak tanımlanır. Algoritmanın kazandığı herhangi bir deneyim, herhangi bir zamandaki veri örneklerinden ya da veri noktalarından elde edilebilir. Geçmiş verileri kullanarak tek seferde veri örnekleri beslenebilir ya da gerçek zamanlı olarak yeni veri örnekleri her alındığında eklenebilir. Bu nedenle eğitmek, olarak da bilinen yinelemeli bir süreç olarak ortaya çıkar.

# Makine Öğrenmesinde Performans

Herhangi bir  $T$  görevini yerine getirmesi için  $E$  deneyimi kazanmış bir makine öğrenmesi modeli oluşturulduğu düşünülürse bu modelin ne kadar verimli ve etkin olduğunu görmek amacıyla modelin performansı  $P$  burada kullanılır. Makine öğrenmesinde Performans (yani  $P$ ), genellikle bir algoritmanın ya da modelin görevi ne kadar iyi yerine getirdiğini görmek için kullanılan ya da modelin görevi ne kadar iyi yerine getirdiğini görmek için kullanılan nicel ölçü kriterleridir.

# Makine Öğrenmesinde Performans

Performans ölçümleri genellikle yıllar süren araştırma ve araştırmalardan sonra oluşturulmuş standart ölçülerdir. Sınıflandırmada yaygın kullanılan performans ölçüleri arasında doğruluk (accuracy), kesinlik (precision), hatırlatma (ya da geri çağırma-recall), F1 puanı (F1 score), duyarlılık (sensitivity), özgüllük (specificity), hata oranı (error rate), yanlış sınıflandırma (misclassification rate) sayılabilir. Performans ölçümleri genellikle algoritmanın deneyim E'yi kazanmak için kullandığı, eğitim veri örnekleri ile daha önce modelin hiç görmediği ya da öğrenmediği, genellikle doğrulama ve test veri örnekleri olarak bilinen veri örnekleri üzerinden değerlendirilir. Böylece modelin yalnızca eğitim veri noktaları ile fazla önyargılı hale gelmemesi için geliştirilmesidir.

# Makine Öğrenmesinde Görevler

Görev, deneyim ve performans kavramlarından yola çıkarak yapılan makine öğrenmesi süreci aşağıdaki şekilde verilmiştir.



Figure 3: Makine Öğrenmesi Süreci



# Makine Öğrenmesinde Görevler

Sonuç olarak bir makine öğrenmesi süreci, makineye çok sayıda belirli bir görevi gerçekleştirmek için gerekli olan geçmiş veriler ile besleyerek başlar.

# MAKİNE ÖĞRENMESİ TÜRLERİ

Makine öğrenmesi, bilgisayar sistemlerinin yardımıyla bir problemi çözmeyi öğrenebilen modeller oluşturmak için kullanılan çeşitli teknikleri içermektedir. Adı üzerinde makine öğrenmesinde öğrenme ve deneyim büyük bir önem taşıdığı için her aşaması için uygulanan öğrenme algoritmalarına ve yöntemlerine göre türlere ayrılmıştır. Bazı kaynaklarda makine öğrenmesi tekniklerinin en geniş biçimdeki hali aşağıdaki şekilde gösterilmiştir.

# MAKİNE ÖĞRENMESİ TÜRLERİ




Figure 4: Makine Öğrenmesi Türleri

# Bazı makine öğrenmesi türlerinin görevleri

Denetimli makine öğrenmesi ile ilgili olarak, öğrenme, belirli bir görev hakkında geçmiş deneyim için bir dizi örneğin kullanılması-sağlıklı ya da kırmızı-yeşil gibi kategorilere ayrılmış, insan uzmanlar tarafından onaylanmış etiketli ayrık hedef değişkeni gruplarına sahipse sınıflandırma görevlerinde kullanılır Makine öğrenmesi sürecinde model oluşturma ve model değerlendirme aşamaları vardır. Bu aşamaları vardır. Bu aşamalarda özellikle model oluştururken gerçek dünya problemindeki mevcut verilerin durumu ile birlikte model oluşturma yaklaşımı da önemli bir yer tutar.

# Bazı makine öğrenmesi türlerinin görevleri

Bu nedenle, uygulama alanlarında etkili modeller oluşturmak için, daha önce verilerin doğasına ve hedef sonuca bağlı olarak, farklı türde makine öğrenme teknikleri, öğrenme yeteneklerine göre önemli rol oynayabilir. Model oluşturma da denetimli öğrenme görev odaklı yaklaşım, denetimsiz öğrenme veri odaklı yaklaşım, yarı denetimli öğrenme görev ve veri odaklı yaklaşım pekiştirmeli öğrenme ise çevre odaklı bir yaklaşım sergilemektedir. Model oluşturmada görev türleri ile birlikte çeşitli makine öğrenmesi teknikleri.

# Bazı makine öğrenmesi türlerinin görevleri

Table 1: Yapay Zeka Kavramları.

Öğrenme Türü	Model Oluşturma	Görev Türleri
Denetimli	Görev Odaklı Yaklaşım: Algoritmalar ya da modeller etiketli verilerde öğrenir.	Sınıflandırma, Regresyon (Tahmin)
Denetimsiz	Veri Odaklı Yaklaşım: Algoritmalar ya da modeller etiketsiz verilerden öğrenir.	Kümeleme İlişkilendirme Boyutsal indirme
Yarı Denetimli	Görev ya da Veri odaklı yaklaşım: Modeller birleştirilmiş (Etiketli +Etiketsiz) veriler kullanılarak oluşturulur.	Sınıflandırma Kümeleme
Pekiştirmeli	Çevre odaklı yaklaşım: Modeller ödül ya da cezaya dayalıdır.	Sınıflandırma, Kontrol (denetim)

# Denetimli Öğrenme

Denetimli öğrenme, genel olarak, bir işlevi ya da görevi öğrenmek için, örnek-girdi-çıktı veri çiftlerine dayalı olarak yapılan öğrenme ile yeni girilen bir girdiyi bir çıktıya eşleyen makine öğrenmesi modelidir. Şekilde yer alan verilen denetimli öğrenme sürecinde gösterildiği gibi bir işlevi çıkarmak için insan uzmanlar tarafından etiketlenmiş eğitim verilerini ya da bir eğitim örnekleri dizisini kullanır.

# Denetimli Öğrenme

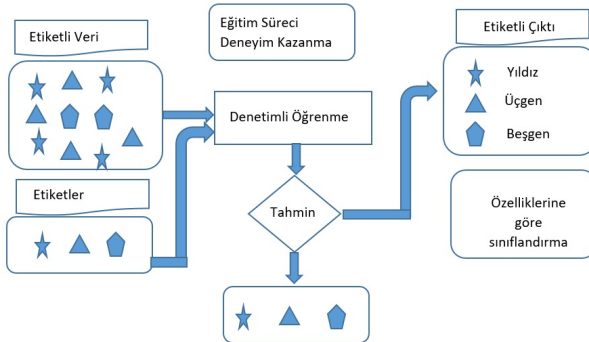


Figure 5: Denetimli Öğrenme Süreci



# Denetimli Öğrenme

Denetimli öğrenmede amaç, çoklu eğitim verisi örneklerine dayalı olarak girdi veri örnekleri  $x$  ile bunlara karşılık gelen çıktılar  $y$  arasında eşleme ya da ilişki öğrenmektir. Bu öğrenilen bilgi daha sonra gelecekte model eğitimi süreci sırasında daha önce bilinmeyen ya da görülmeyen herhangi bir yeni girdi veri örneği  $x$  için bir çıktı  $y$  tahmin etmek için kullanılabilir.

# Denetimsiz Öğrenme

Denetimsiz öğrenme, model ya da algoritma, etiketli çıktılar ya da sonuçlar biçiminde açıklamalar sağlamak gibi herhangi bir yardım ya da denetim olmaksızın verilen verilerden doğal gizli yapıları, örüntüleri ve ilişkileri öğrenmeye çalışır. Denetimsiz öğrenme, denetimli öğrenmedeki gibi önceden mevcut hedefi belirli eğitim verilerine dayanarak bazı sonuçları tahmin etmeye çalışmak yerine, verilerden anlamlı örüntüler ya da bilgiler çıkarmaya çalışmakla daha fazla ilgilenir.

# Denetimsiz Öğrenme

Denetimsiz öğrenmenin sonuçlarında daha fazla belirsizlikler vardır, ancak yalnızca ham verilere bakarak bu modellerden daha önce görüntülenemeyen birçok bilgi de elde edilebilir. Denetimsiz öğrenme, etiketlenmemiş veri kümelerini insan müdahalesine yani veri odaklı bir sürece ihtiyaç duymadan analiz eder.

# Denetimsiz Öğrenme

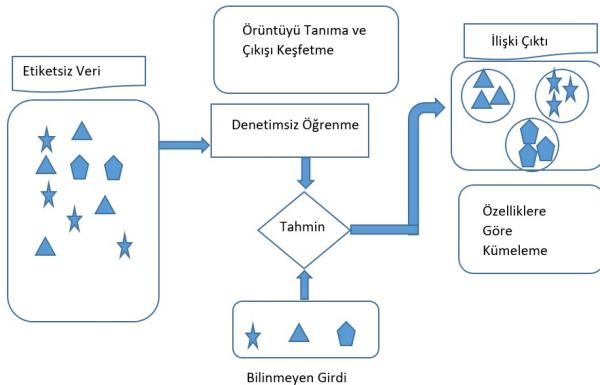


Figure 6: Denetimsiz Öğrenme

# Yarı-Denetimli Öğrenme

Yarı denetimli öğrenme aynı anda etiketli ve etiketsiz verileri içerir. Bu bakımdan bahsedilen denetimli ve denetimsiz öğrenme yöntemlerinin karması durumundadır. Yarı denetimli öğrenme yöntemleri, genellikle denetimli ve denetimsiz öğrenme yöntemleri arasında yer alır. Gerçek dünyada, çeşitli bağlamlarda etiketli veriler az sayıda ve etiketlenmemiş faydalı veriler çok sayıda olabilir, bu gibi durumlar yarı denetimli öğrenme gereksinimi ortaya çıkarmıştır.

# Yarı-Denetimli Öğrenme

Yarı denetimli öğrenme yöntemleri genellikle denetimsiz öğrenme bileşenini oluşturan etiketlenmemiş çok sayıda eğitim verisi ve az miktarda denetimli öğrenme bileşenini oluşturan önceden etiketlenmiş tanımlı veri kullanır. Üretken yöntemler, grafik tabanlı yöntemler ve sezgisel tabanlı yöntemler şeklinde çok teknikleri mevcuttur.

# Pekiştirmeli Öğrenme

Pekiştirmeli öğrenme yöntemleri, geleneksel denetimli ya da denetimsiz yöntemlerden biraz farklıdır. Bu bağlamda, şekilde görüldüğü gibi belirli bir ortamla etkileşim kurmak ve çevre üzerinde gerçekleştirdiği eylemlerin türüne göre belirli bir süre boyunca eğitmek istenilen bir öğrenme sistemi aracı olsun. Genel olarak bu öğrenme aracı, çevre ile etkileşim için bir dizi strateji ya da politika ile başlar. Çevreyi gözlemlerken, bir kurala ya da politikaya dayalı olarak ve çevrenin geçerli durumunu gözlemleyerek belirli bir eylemde bulunur.

# Pekiştirmeli Öğrenme

Eyleme bağlı olarak, temsilci, zararlı olabilecek bir eylemde ceza ya da faydalı olabilecek bir eylemde ödül alır. Gerekirse mevcut politika ve stratejilerini günceller ve bu yinelemeli süreç, istenen ödülleri elde etmek için çevresi hakkında yeterince şey öğrenene kadar devam eder.



# Pekiştirmeli Öğrenme




Figure 7: Pekiştirmeli Öğrenme Süreci

Toplu öğrenme yöntemleri, popüler olarak çevrimdışı öğrenme yöntemleri olarak da bilinir. Bunlar, modelin tek seferde tüm mevcut eğitim verileri kullanılarak eğitildiği uçtan uca makine öğrenmesi sistemlerinde kullanılan makine öğrenmesi yöntemleridir. Eğitim tanımlandıktan ve model öğrenme sürecini tamamladıktan sonra, tatmin edici bir performans elde ettikten sonra, yeni veri örnekleri için çıktıları tahmin ettiği üretime dağıtılır.

Ancak model, yeni verilerle sürekli olarak belirli bir süre boyunca öğrenmeye devam etmez. Eğitim tamamlandığında model öğrenmeyi durdurur. Bu nedenle, model verilerle tek bir toplu iş halinde eğitildiğinden ve bu genellikle tek seferlik bir prosedür olduğundan, bu toplu ya da çevrimdışı öğrenme olarak bilinir.

# Çevrimiçi Öğrenme

Çevrimiçi öğrenme yöntemleri, toplu öğrenme yöntemlerine göre farklı bir şekilde, eğitim verileri genellikle algoritmaya birden fazla artımlı gruplar halinde beslenir. Bu veri grupları, makine öğrenmesi terminolojisinde mini partiler olarak da bilinir. Ancak, toplu öğrenme yöntemlerinden farklı olarak eğitim süreci burada bitmez. Tahmin için kendisine gönderilen yeni veri örneklerine dayalı olarak belirli bir süre boyunca öğrenmeye devam eder. Temel olarak, tüm modeli önceki veri örneklerinde yeniden çalıştırmak zorunda kalmadan anında yeni verilerle süreçte tahmin eder ve öğrenir.

# Örnek Tabanlı Öğrenme

Girdi verilerine dayalı olarak genelleştirilmeye çalışan yöntemleri kullanarak makine öğrenmesi modelleri oluşturmanın çeşitli yolları vardır. Örnek tabanlı öğrenme, eğitim verileri üzerinde açık bir model oluşturmak ve ardından bunu test etmek yerine daha yeni, daha önce görülmemiş veri örneklerinin sonuçlarını bulmak için ham veri noktalarını kullanan maline öğrenmesi sistemlerini ve yöntemlerini içerir. Örnek olarak bir K-en yakın komşu algoritmasında ilk eğitim verileri olduğunu ve  $k=3$  varsayarak; Makine öğrenmesi yöntemi, boyutları, her veri noktasının konumu gibi özelliklerden verilerin temsiliğini bilir.

# Model Tabanlı Öğrenme

Model tabanlı öğrenme yöntemleri, eğitim verilerine dayalı genelleşmeye yönelik daha geleneksel bir makine öğrenmesi yaklaşımıdır. Tipik olarak, girdi verilerinin özellikleri çıkarmak için kullanıldığı ve modellerin öne çıkan parametreler olarak bilinen çeşitli model parametrelerine dayalı olarak oluşturulduğu yinelemeli bir süreç gerçekleşir.

# MAKİNE ÖĞRENMESİ SÜREÇ ADIMLARI

Yapay zekanın bir alt dalı olarak bakıldığında makine öğrenmesi temel olarak “öğrenme” yoluyla kendini geliştiren ve sonuç olarak görevini yerine getirmede giderek daha yetkin hale gelen bir algoritma ya da modeldir. Günümüzde makine öğrenmesi uygulamaları tıp, e-ticaret, bankacılık gibi birçok farklı alanların hızla ayrılmaz bir parçası haline gelmiştir. Makine öğrenmesi süreci, birçok kaynakta birkaç adımın başlığı değişmekle birlikte çoğunlukla aşağıda listelenen 7 adımdan oluşmaktadır.

# MAKİNE ÖĞRENMESİ SÜREÇ ADIMLARI

- ❶ **Problem Belirlenmesi:** Bir makine öğrenmesi modeli oluştururken, öncelikle gerçek dünya problemindeki görev tam olarak anlaşılmalıdır.
- ❷ **Veri Toplama:** Gerekli veri türlerini öğrendikten sonra, bu verileri nasıl türetebileceğiniz anlamalısınız. Çözmek istediğiniz problem göz önüne alındığında, araştırmanız ve makinenizi beslemek için kullanılacağınız verileri elde etmeniz gerekecektir.
- ❸ **Veri hazırlama ve analiz etme:** Toplanmış durumundaki veriler genellikle net ve doğru biçimde değildir. Veri setinde fazlalıklar, eksik değerler ve hatta mükerrer durumundaki değerler nedeniyle birçok tutarsızlıkla karşılaşma ihtimali vardır. Söz konusu tutarsızlıkları ortadan kaldırmak çok önemlidir.



# MAKİNE ÖĞRENMESİ SÜREÇ ADIMLARI

- ❶ **Model seçimi:** Veri hazırlama ve analiz etme adımından sonra, model seçimi yapılır. Günümüze kadar araştırmacılar tarafından geliştirilen ve farklı doğrultuda işe koşulabilecek çeşitli modeller vardır. Bu modeller farklı hedefler düşünülerek tasarlanmıştır. Burada uygulanan algoritmalar arasında veriye ve değişkenlere uygun algoritmanın seçimi önem arz etmektedir.

# MAKİNE ÖĞRENMESİ SÜREÇ ADIMLARI

- 5 **Modelin eğitimi:** Makine öğrenmesi sürecinin merkezinde modelin eğitimi yer alır. İstenilen seviyede bir öğrenme için modelin yapılandırılması işlemlerinin büyük kısmı bir aşamada yapılır. Eğitim sabır ve deneyim gerektirir. Modelin uygulanacağı alan hakkında bilgi sahibi olmak da ayrıca katkı sağlayacaktır.
- 6 **Model değerlendirme:** Eğitim veri seti yardımıyla bir model oluşturduktan sonra sıra model değerlendirmeye gelmektedir. Eğitilen modelle, gerçek dünya durumlarında iyi çalışıp çalışmayacağını görmek için test edilmesi gerekir. Değerlendirme, veri bilimcilerinin ulaşmak için belirledikleri hedeflere ulaşip ulaşmadığını kontrol etmek için işe koşturmaktadır.

# MAKİNE ÖĞRENMESİ SÜREÇ ADIMLARI

- ❶ **Tahmin ya da çıkarım:** Makine öğrenmesi sürecinin son adımı tahmin ya da çıkarım aşamasıdır. Model değerlendirilip gerekirse iyileştirildikten sonra, tahminlerini bulmak için kullanılır. Hedef çıktı, doğru ya da yanlış gibi kategorik değişken olabileceği gibi bir hisse senedinin tahmini değeri bir sürekli değer de olabilir.

**Veri toplama ve hazırlama adımı:** Görevin gerçekleştirilmesi için gerekli olan verilerin seçilmesi, nereden alınacağını belirlenmesi, veri ön işleme aşaması ve özellik seçimi gibi veriler hazır olana kadar yapılan tüm işlemlerdir

# MAKİNE ÖĞRENMESİ SÜREÇ ADIMLARI

**Özellik seçimi ve özellik mühendisliği:** Veriler makine öğrenmesi modeli için hazır hale geldikten sonra veriler makine öğrenmesi modeline alınıncaya kadar kullanılacak özelliklerin seçimi, çıkarımı ve düzenlenmesi anlamında yapılan tüm değişiklikleri içeren adımdır.

**Makine öğrenmesi algoritmasını seçmek ve modeli eğitmek:** Gerçekleştirilecek görev için uygun malime öğrenmesi modelini oluşturmak ve deneme yanılma işlemleri sonunda seçilen parametrelerle modeli geliştirme aşamasıdır.

**Modelimizin değerlendirmesi:** Bu adım modelin değerlendirilmesi için gerekli ölçüleri seçerek gerçek değerlendirmenin yapılmasını içerir.

# MAKİNE ÖĞRENMESİ SÜREÇ ADIMLARI

**Model ince ayar, düzenlileştirme ve öne çıkan parametre ayarı:** Modelin elde edeceği başarıma göre bazı seçilen parametreler düzenlenebilir. Burada, yeterince iyi olduğuna inanılan bir model elde edilene kadar modele tekrar farklı eğitim ve test verileri verilerek gerekli parametre düzenlemeleri gerçekleştirilir.

# MODEL DEĞERLENDİRME VE SINIFLANDIRMA PERFORMANS ÖLÇÜLERİ

Uygun modelin elde edilmesinden sonraki adım, test veri kümeleri üzerinden elde edilecek baı performans ölçülerine göre modelin etkinliđi hakkında fikir elde etmektedir. Makine öğrenmesi modelinizi değerlendirmek için seçtiđiniz ölçütler oldukça kritiktir. Ölçü seçimi, makine öğrenme algoritmalarının performansının ölçülme ve karşılaştırılma biçimini etkilemektedir.

# MODEL DEĞERLENDİRME VE SINIFLANDIRMA PERFORMANS ÖLÇÜLERİ

Performans ölçüleri ve özelliklerine geçmeden önce makine öğrenmesi süreç adımlarını da göz önüne alarak bazı kritik kavramları hatırlamakta fayda vardır. Öncelikle elde edilen veriler eğitim seti, doğrulama seti ve test seti olmak üzere üç veri setine, küçük bir kısmı değerlendirme ve test verileri için ayrılır. Bazı durumlarda sadece eğitim ve test verileri olmak üzere iki gruba ayrılır. Bu setler ve görevleri aşağıda verilmiştir.

# MODEL DEĞERLENDİRME VE SINIFLANDIRMA PERFORMANS ÖLÇÜLERİ

**Eğitim seti:** Eğitim veri setindeki verileri kullanarak modelin öğrenme aşaması gerçekleştirilir. Makine öğrenmesi modelleri, eğitim veri setindeki girdilerden öğrenirler. İyi bir öğrenme ve modelin iyi bir genelleme yapılabilmesi için eğitim veri setinde gerçekleştirilecek görevle ilgili mümkün olduğunda çok veri bulunmalıdır. Genellikle verilerin miktarına göre %70 ya da %80'lik kısmı eğitim veri setine ayrılır.



# MODEL DEĞERLENDİRME VE SINIFLANDIRMA PERFORMANS ÖLÇÜLERİ

**Doğrulama seti:** Doğrulama seti makine öğrenmesi modelinin değerlendirilmesi ve adı üstünde doğrulama işlemi için kullanılır. Doğrulama seti pratik olarak eğitim veri setinden geriye kalan kısmın yarısı (%15 ya da %10 gibi) ayrılır.

**Test veri seti:** Test veri seti, oluşturulan makine öğrenmesi modelinin yine hiç görmediği verilerle son testinin yapılması amacıyla kullanılır. Böylece modelin seçilen performans ölçüleri yetenekleri ortaya konur.

# MODEL DEĞERLENDİRME VE SINIFLANDIRMA PERFORMANS ÖLÇÜLERİ

**Doğru pozitifler (TP):** Doğru pozitifler ilgili verilerin tekabül ettiği gerçek sınıfın doğru olduğu ve tahmin edilenin de doğru olduğu durumları ifade etmektedir.

**Yanlış pozitifler (FP):** Yanlış pozitifler, ilgili verilerin tekabül ettiği gerçek sınıfın yanlış ve tahmin edilenin doğru olduğu durumlara karşılık gelmektedir.

**Doğru negatifler(TN):** Doğru negatifler, ilgili verilerin tekabül ettiği gerçek sınıfın yanlış olduğu ve tahmin edilenin de yanlış olduğu durumlardır.

**Yanlış negatifler(FN):** Yanlış negatifler, ilgili verilerin tekabül ettiği gerçek sınıfın doğru ve tahmin edilenin olduğu durumları ifade etmektedir.

# MODEL DEĞERLENDİRME VE SINIFLANDIRMA PERFORMANS ÖLÇÜLERİ

## Karışıklık Matrisi:

Sahtekarlık tespiti, kayıp analizi, hastalık tespiti ve görüntü sınıflandırması gibi alanlarda yaygın olarak kullanılan makine öğrenmesi tekniklerinden birisi olan sınıflandırma modellemesinde model performansını bulmak için genellikle sınıflandırma sonuç tablosunu kullanılır. Sınıflandırma performansı en iyi şekilde karışıklık matrisi ya da doğruluk tablosu (confusion matrix) adı verilen uygun bu araçla tanımlanabilir.

# MODEL DEĞERLENDİRME VE SINIFLANDIRMA PERFORMANS ÖLÇÜLERİ

		GERÇEK	
		Pozitif	Negatif
TAHMİN	Pozitif	<b>TP</b>	<b>FP</b>
	Negatif	<b>FN</b>	<b>TN</b>

Figure 8: 2 çıkış sınıfı bulunan bir sınıflandırma modeli için örnek karşılık matrisi tablosu ve ilgili hücre isimleri

# MODEL DEĞERLENDİRME VE SINIFLANDIRMA PERFORMANS ÖLÇÜLERİ

Bu karışıklık matrisi geleneksel olarak yukarıdaki resimlerde gösterildiği gibi  $2 \times 2$  bir matris olarak düzenlenmiştir. Tahmin edilen sınıflar satırlar halinde yatay olarak düzenlenir ve gerçek sınıflar sütunlar halinde dikey olarak düzenlenir, ancak bazen bu tersine çevrilir.

Karışıklık matrisinde de gösterilen dört durum bundan sonraki yaygın olarak sınıflandırma performansı ölçülerini anlamak ve açıklamak için kullanılacaktır. Daha önce belirtildiği gibi, mükemmel bir sınıflandırıcının yanlış, pozitif ve yanlış negatif için hiçbir giriş olmaması gerekir, yani yanlış pozitif sayısı=yanlış negatif = 0 olmalıdır.

# MODEL DEĞERLENDİRME VE SINIFLANDIRMA PERFORMANS ÖLÇÜLERİ

## Doğruluk (Accuracy):

Sınıflandırma modellemede en yaygın kullanılan performans değerlendirme ölçüsüdür. Bu ölçü doğru tahminlerin değerlendirilen toplam sayısına oranını ölçmektedir. Doğruluk, sınıflandırıcının seçilmesi gereken tüm durumları seçmesi ve reddedilmesi gereken tüm durumları reddetme yeteneği olarak tanımlanır. %100 doğruluğa sahip bir sınıflandırıcı için bu  $YN=YP=0$  anlamındadır.

$$\text{Doğruluk (Accuracy)} = \frac{TP+TN}{TP+FP+FN+TN}$$

# MODEL DEĞERLENDİRME VE SINIFLANDIRMA PERFORMANS ÖLÇÜLERİ

**Duyarlılık (hassasiyet) ya da hatırlama ( Sensitivity or recall):**

Duyarlılık (sensitivity) performans ölçüsü, bir sınıflandırıcının seçilmesi gereken tüm durumları seçebilmesidir. Duyarlılık ölçüsü, doğru şekilde sınıflandırılan pozitif kalıpların oranını ölçmek için kullanılır. Hatırlatma (recall), tüm ilgili durumlar arasında fiilen bulunan ilgili durumların oranı olarak tanımlanır ya da doğru pozitiflerin sayısıdır.

# MODEL DEĞERLENDİRME VE SINIFLANDIRMA PERFORMANS ÖLÇÜLERİ

Mükemmel bir sınıflandırıcı tüm doğru pozitifleri seçer ve hiçbir doğru pozitifleri kaçırmaz. Başka bir deyişle, yanlış negatifler olmayacaktır. Gerçekte, herhangi bir sınıflandırıcı bazı doğru pozitifleri genelleme ile bulacak ve dolayısıyla yanlış negatiflere sahip olacaktır.

Duyarlılık ya da hatırlatma (Sensitivity or Recall) =  $\frac{TP}{TP+FN}$



# MODEL DEĞERLENDİRME VE SINIFLANDIRMA PERFORMANS ÖLÇÜLERİ

## Özgüllük (Specificity):

Duyarlılığın aksine, özgüllük ölçüsü, doğru sınıflandırılmış negatif kalıpların oranını ölçmek için kullanılır. Tüm gerçek olumsuz durumlardan kaç tanesinin olumsuz olarak tanımlandığı bulunur. Bir başka deyişle özgüllük, bir sınıflandırıcının reddedilmesi gereken tüm durumları reddetme yeteneğidir.

# MODEL DEĞERLENDİRME VE SINIFLANDIRMA PERFORMANS ÖLÇÜLERİ

Mükemmel bir sınıflandırıcı tüm doğru negatifleri reddedecek ve beklenmedik sonuçlar vermeyecektir. Başka bir deyişle, hiç yanlış pozitif değeri olmayacaktır. Gerçekte, herhangi bir sınıflandırıcı, reddedilmesi gereken bazı vakaları seçecek ve bu nedenle bazı yanlış pozitif değerlere sahip olacaktır.

$$\text{Özgüllük (Specificity)} = \frac{TN}{FP+TN}$$

# MODEL DEĞERLENDİRME VE SINIFLANDIRMA PERFORMANS ÖLÇÜLERİ

## Kesinlik (Precision):

Kesinlik, aynı koşullar altında tekrarlanan ölçümlerin aynı sonucu gösterme derecesidir. Kesinlik, sınıflandırıcının pozitif olarak bildirdiği grupta gerçekten pozitif bir sınıftaki toplam tahmin edilen modellerden doğru bir şekilde tahmin edilen pozitif kalıpları ölçmek için kullanılır. Kesinlik ne kadar yüksek olursa, model tarafından yapılan yanlış pozitiflerin sayısı o kadar düşük olur.

$$\text{Kesinlik (Precision)} = \frac{TP}{TP+FP}$$

# MODEL DEĞERLENDİRME VE SINIFLANDIRMA PERFORMANS ÖLÇÜLERİ

## F1 Skoru (F1 score ya da F measure):

Performans değerlendirme ölçülerinden sonucu F1 puanıdır.

$$\text{F1 skoru} = 2 * \frac{\text{kesinlik} * \text{hatırlatma}}{\text{kesinlik} + \text{hatırlatma}}$$

Yukarıda gördünüz gibi bazen Yanlış pozitif bazen de yanlış negatif ağırlık verilmesi gerekiyor. F1 skoru, hatırlatma ve kesinlik değerleri arasındaki ağırlıklı ortalamasıdır. Bu yanlış pozitif ve yanlış negatif eşit önem verildiği anlamına gelir. Böylelikle Doğruluk ile karşılaştırıldığında çok faydalı bir ölçüdür.

# MODEL DEĞERLENDİRME VE SINIFLANDIRMA PERFORMANS ÖLÇÜLERİ

Doğruluk %95 pozitif sınıf ve %5 negatif sınıf içeren bir eğitim veri seti gibi dengesiz bir veri setimiz varsa, model sonunda pozitif sınıf sınıfı doğru şekilde tahmin etmeyi öğrenecek fakat negatif sınıfı tanımlayacağınızı öğrenmeyeceği için test veri setinde yüksek değerler verecektir. Bu nedenle modelin asıl performansı doğrulukla tam olarak ölçülemeyebilir. Bu nedenle, veri kümesi dengesiz olduğunda F1 skoru kullanılması önerilmektedir.

# ROC Eğrisi ve AUC değeri

## ROC Eğrisi:

Bir ROC eğrisi (Receiver Operating Characteristic Curve- Alıcı İşletim Karakteristik Eğrisi), tüm sınıflandırma eşiklerinde bir sınıflandırma modelinin performansını gösteren bir grafikdir. Bu bir sınıflandırma modelinin duyarlılığını ve özgüllüğünü gösteren bir grafikdir. Bu iki ölçüyü kısaca hatırlatmak gerekirse; doğru pozitif oranı (TPR) olarak da bilinen Duyarlılık sonuç gerçekten olumluyken, modelin bir gözlem için olumlu bir sonuç öngöreme olasılığını verir. Doğru negatif oranı (TNR) olarak da bilinen özgüllük ise sonuç gerçekten olumsuz olduğunda , modelin bir gözlem için olumsuz bir sonuç ön görme olasılığını verir.

# ROC Eğrisi ve AUC değeri

Bir ROC eğrisi, bir parametrenin farklı kesme noktalarına karşılık olarak, yanlış pozitif oranının (NPR 1-Özgüllük) fonksiyonunda doğru pozitif oranın (TPR-duyarlılık) grafiğidir. ROC eğrisi, TPR'nın y ekseninde ve NPR'nın x ekseninde olduğu eğrisi, TPR'ye karşı NPR ile çizilir. ROC eğrisi üzerinde gözlenebilen her nokta spesifik bir karar eşğine karşılık gelen duyarlılık-özgüllük çiftini temsil eder.

# ROC Eğrisi ve AUC değeri

$$\text{TPR} = \text{TP} / (\text{TP} + \text{FN})$$

$$\text{FPR} = \text{FP} / (\text{FP} + \text{TN})$$

ROC eğrisi, modelin farklı sınıflandırma eşiklerinde TPR'ye karşı FPR'yı çizer. Sınıflandırma eşiğinin düşürülmesi, daha fazla ögeyi pozitif olarak sınıflandırır.

ROC eğrisinin altındaki alan (AUC), bir parametre kapasamının, hastalıklı/normal gibi tanı grubunu ne kadar iyi ayırt edebileceğinin bir ölçüsüdür.



# ROC Eğrisi ve AUC değeri




Figure 9: ROC eğrisi Örneği

# ROC Eğrisi ve AUC değeri

## AUC değeri:

Şekilde görüldüğü gibi AUC, “ROC Eğrisinin Altındaki Alan” ölçüsüdür. Yani AUC (0,0) ile (1,1) arasındaki tüm ROC eğrisinin altındaki tüm iki boyutlu alanı ölçer. AUC-ROC eğrisi, farklı eşik ayarlarında olmak üzere; sınıflandırma problemlerine tekabül eden bir performans ölçümüdür. AUC ayrılabilirliğin derecesini ya da ölçüsünü temsil eder ve ROC bir olasılık eğrisidir. Modelin sınıfları ne kadar ayırt edebildiğini açıklar. AUC ne kadar yüksekse modelin de sınıfları doğru tahmin etmede o kadar iyi olduğu söylenebilmektedir.

# ROC Eğrisi ve AUC değeri

Yani hastalık teşhisi yapan modelde AUC yüksekse model hastalığı olan ve olmayanları ayırt etmede iyidir denilebilir. İdeal bir modelin AUC'si 1'e yakındır. Bu durum modelin iyi bir ayrılabilirlik ölçüsüne sahip olduğunu göstermektedir. Zayıf bir modelin AUC değeri ise 0'a yakındır; model kötü ayrılabilirlik ölçüsüne sahiptir. AUC 0.5 olduğunda ise söz konusu modelin hiçbir şekilde doğru sınıf ayrımı yapamadığı anlamına gelmektedir.

Makine öğrenmesinin türlerini anlatırken bilişsel bilim ve bilişsel modelleme kavramlarını da kullandık. Aslında çok tanıdık gelecek olan bu terimleri ve anlamlarını kısaca açıklayalım. Bilişsel bilim, beynin, özellikle insan beyninin, algılama, öğrenme, hatırlama, düşünme, tahmin etme, çıkarım yapma, problem çözme, karar verme, planlama ve çevrede hareket etme gibi karmaşık görevleri yerine getirmek için kullandığı süreçleri anlamakla ilgilenmektedir. Bilişsel bilimin başlıca teorik dergilerinde yer alan çalışmaların büyük bir çoğunluğu bilişsel modellemeyi içerir.

Bilişsel modeller, algıdan hafızaya, problem çözme ve karar vermeye kadar bilişin tüm alanlarında hızla artan bir oranda ortaya çıkmaktadır. Bilişsel bir modelin amacı, bu temel bilişsel süreçlerin bir ya da daha fazlasını bilimsel olarak açıklamak ya da bu süreçlerin nasıl etkileşimde girdiğini açıklamaktır. Ayrıca, bilişsel modelleme uygulamaları, insan faktörleri, klinik psikoloji, bilişsel sinirbilim, ekonomide etmen temelli modelleme ve daha pek çok alana yayılmaya başlamaktadır.

Aslında bilişsel modellemede yer alan adımlar hemen hemen makine öğrenmesi modellemede olduğu gibidir. Temel olarak başlangıç için problemin ve istenilen çıkarımın en iyi şekilde anlaşılması gerekmektedir. Bundan sonraki adımlar aşağıdaki gibi sıralanabilir;

- ❶ Bilişsel modelleme de ilk adım, modeli oluşturmak için kavramsal teorinin temel bilişsel ilkeleri kullanmaktır. Kavramsal teorik çerçeveyi ele alarak matematiksel ya da bilgisayar dili tanıma uyacak şekilde yeniden düzenlemektir.
- ❷ İkinci adım, genellikle kesin nicel tahminler üretmek için kavramsal teoride tam olarak ifade edilemeyen varsayımlar için ek varsayımlar yaparak modeli tamamlamaktır.

- ③ Üçüncü adım, bilişsel modellerde başlangıçta hemen her zaman bulunan bilinmeyen parametreleri ya da katsayıları gözlenebilen bazı verilerden tahmin etmektir.
- ④ Dördüncü adım, model değerlendirme aşamasıdır. Burada verilememekle birlikte bilişsel modelleme için geliştirilmiş ve kabul edilmiş birçok model bulunmaktadır. Bu adım oluşturulan bilişsel modelden elde edilen çıktıların hedeflenen sonuçlara ne kadar yakın olduğunu görme ve yeteneklerine göre diğer bilişsel modellerin tahminleri ile karşılaştırmaktadır.



- 5 Beşinci ve son adım, genellikle baştan başlamak ve teorik çerçeveyi yeniden formüle etmek ve yeni deneysel sonuçlardan elde edilen geri bildirimler ışığında yeni modeller oluşturmaktır. Model geliştirme ve test etme, hiç bitmeyen bir süreçtir. Her zaman yeni deneysel bulgular keşfedilmekte ve önceki modellere yeni zoruklar çıkarmaktadır. Bu yeni sonuçları hesaba katmak için önceki modellerin değiştirilmesi ya da genişletilmesi gerekmektedir. Böylece modelleme süreci, bir alandaki bilim ilerledikçe zaman içinde gelişen ve daha güçlü hale gelen modellerin evrimini üretir.